

EWAT : réponses anticipées aux critiques

3 slides défensives pour la soutenance

Wassim Badraoui

Devoteam — EPITA

Mai 2026

Slide 1 — Verdict synthétique : stress tests H3

Pourquoi l'AUROC=0.987 n'est pas la métrique défensive

La critique soulevée

« L'AUROC=0.987 est trop bon et suspect. »

La réponse en 5 stress tests

Test	Question	Verdict
A1 distant-window	Précursion temporelle sur labels EWAT ?	$\Delta = -0.007 \rightarrow$ fuite
A2 LOSO precursor	Généralisation à un type inédit ?	top-1 = 0.51 polarisé
A3 permutation	Signal réel ou bruit ?	$p < 0.01 \rightarrow$ signal réel
A4 filtre $n_{\text{pos}} \geq 5$	Clusters statistiquement reportables ?	5/10 (AUROC moyen = 0.975)
A5 paired $\Delta(B_4 - B_3)$	STGCN apporte-t-il du gain ?	IC=[-0.03, +0.04] contient 0

Conclusion

L'AUROC=0.987 mesure la **cohérence interne** du clustering EWAT (cible auto-référente), pas la précursion temporelle. Cette critique est **reconnue et adressée** par les Phases B et C ci-après.

Scripts : `experiments/h3_robustness/`.

Slide 2 — Headline honnête : 0.92 sur cible Chaos Mesh

Évaluation indépendante avec IC bootstrap explicites

Pivot méthodologique (Phase B + C)

Remplacer la cible (cluster EWAT) par les **15 scénarios Chaos Mesh** (vérité terrain indépendante du pipeline).

Headline défensif final (multi-seed, 10 graines, v4_strat)

Évaluation	macro-AUROC	IC 95 % / std
H3 EWAT-labels (circulaire)	0.990 ± 0.012	10 graines
B2 LR-OvR Chaos Mesh stratified	0.9201	[0.878, 0.956]
B2 LOSO macro-AUROC	0.9298	15 folds
H1 silhouette test (10 graines)	0.691 ± 0.115	range [0.52, 0.84]
A1 $\Delta(\text{far} - \text{near})$ EWAT	-0.012 ± 0.022	LEAK 9/10

Précursion temporelle confirmée (C2-A1)

Sur le modèle STGCN entraîné directement sur Chaos Mesh, $\Delta(\text{far} - \text{near}) = -0.116$ — la dynamique, 377

Slide 3 — Reframe des contributions

Quatre axes défendables (et un résultat négatif honnête)

- ❶ **Géométrique** (contribution principale et défendable)
 - H1 silhouette = 0.782 ± 0.065 (10 graines, min 0.62)
 - Mismatch corrigé : average+cosine vs ward+euclidean $\rightarrow +51\%$
- ❷ **Ontologique** (Phase 8, OWL/RDF formelle)
 - 29 classes ancrées littérature (Soldani & Brogi, Fu et al., Gregg, Aniello)
 - 143 individus ABox, 11 object properties, raisonneur HermiT cohérent en 0.61s
 - 3 causales (BH-FDR), 19 co-occurrences, 46 edges propagation
- ❸ **Méthodologique** (stress tests + open-set)
 - 5 stress tests (A1–A5) qui transforment la critique en transparence
 - OpenMax/EVT pour la détection de scénarios inédits (Bendale & Boulton 2016)
- ❹ **Prédictive honnête** (Phase B/C)
 - macro-AUROC = 0.920 sur Chaos Mesh v4_strat, IC [0.878, 0.956]
 - Précursion temporelle confirmée ($\Delta(\text{far} - \text{near}) = -0.116$)

Résultat négatif assumé

H2a look-through MMD² **définitivement falsifié** (v3 : $p = 0.27$, v4_strat : $p = 0.37$). Mécanisme falsifié, pas juste la durée d'épisode.
Résultat scientifique honnête.

Bonus — Anticipation des questions

« Votre AUROC=0.987 est suspect »

Oui, et c'est pourquoi nous reportons **0.920 sur Chaos Mesh indépendant (slide 2)**. Le 0.987 est explicitement étiqueté comme cohérence interne du clustering.

« L'encodeur STGCN n'aide pas »

Vrai en agrégé (A5 paired Δ IC contient 0). Sa valeur est **géométrique** (H1 sil = 0.78) et **ontologique** (Phase 8). En prédiction agrégée, un LR sur features brutes instance-normalisées suffit (B2 = 0.920).

« Vous évaluez sur les scénarios d'entraînement »

Oui pour H3, et c'est pourquoi nous ajoutons :

- LOSO macro-AUROC = 0.930 ± 0.007 (15 folds, retrain par fold)
- OpenMax/EVT pour les scénarios totalement inédits (Phase C3)
- LOSO top-1 = 0 reconnu comme limitation tautologique d'un classifieur fermé

« Pourquoi ewat_v4_strat et pas ewat_v4 ? »

Le split temporel original ewat_v4 avait 4 scénarios entièrement absents du training : AUROC = 0.500

Slide 5 — Validation opérationnelle

Latence end-to-end (C-3) + power statistique (C-5)

Latence E2E (200 itérations CPU)

Étape	médiane	p95	budget
Drift (0)	0.01	0.01	1000 ms
Encoder+Siamois (1+2)	0.96	1.97	2000 ms
Précurseurs (3)	1.85	3.91	1000 ms
TOTAL	9.3	13.3	5000

375× sous budget

Verdict : ●

Power statistique (Hanley-McNeil)

- 5/10 clusters reportables ($n_{\text{pos}} \geq 5$)
- Power moyenne sur reportables : 1.0
- C6, C9 ($n_{\text{pos}} = 1$) marqués *non concluant*

Cible future : $n_{\text{pos}} \geq 17$ pour détecter AUROC = 0.7 avec power > 0.8.

Conclusion

Le pipeline est **opérationnellement viable** (SLA < 5 s largement respecté) et statistiquement défensible sur les 5 clusters reportables. Les 5 autres clusters sont explicitement marqués comme non concluants par manque d'effectif.

Slide 6 — Limites résiduelles + travaux futurs

8 limites identifiées par audit méthodologique post-Phase C

Limites résiduelles (docs/limitations.md L10–L17)

ID	Limite	Travail futur
L10	H1 sil = 0.467 sur v4 (surentraînement siamois)	Hard-negative mining + curriculum
L11	Latence end-to-end	✓ Résolu (C-3, p95 = 13 ms)
L12	OpenMax Unknown AUROC = 0.55 < 0.7	Mahalanobis-OOD / Energy / ODIN
L13	Service graph $N = 6$ vs production 100+	Benchmark $N \geq 20$
L14	Cross-cluster non validé	Stratégie B fine-tuning RCAEval (C-2)
L15	Pas de retraining cycle opérationnel	Drift d'embeddings → trigger retrain
L16	17 features hardcodées	mRMR / SHAP-based pruning
L17	Ontologie sans audit SRE	1 séance audit + intégration runbook

Stratégie globale

Chaque limite est documentée transparente *et* accompagnée d'une proposition de fix technique. **Aucune limite cachée**, aucun fix suspect. Le rapport positionne EWAT comme une **contribution mature avec un programme de recherche clair** pour la suite (L13–L17 : 6+ mois de travaux futurs identifiés).