

# EWAT : réponses anticipées aux critiques

3 slides défensives pour la soutenance

Wassim Badraoui

Devoteam — EPITA

Mai 2026

# Slide 1 — Verdict synthétique : stress tests H3

Pourquoi l'AUROC=0.987 n'est pas la métrique défensive

## La critique soulevée

« L'AUROC=0.987 est trop bon et suspect. »

## La réponse en 5 stress tests

| Test                              | Question                                | Verdict                             |
|-----------------------------------|-----------------------------------------|-------------------------------------|
| A1 distant-window                 | Précursion temporelle sur labels EWAT ? | $\Delta = -0.007 \rightarrow$ fuite |
| A2 LOSO precursor                 | Généralisation à un type inédit ?       | top-1 = 0.51 polarisé               |
| A3 permutation                    | Signal réel ou bruit ?                  | $p < 0.01 \rightarrow$ signal réel  |
| A4 filtre $n_{\text{pos}} \geq 5$ | Clusters statistiquement reportables ?  | 5/10 (AUROC moyen = 0.975)          |
| A5 paired $\Delta(B_4 - B_3)$     | STGCN apporte-t-il du gain ?            | IC=[-0.03, +0.04] contient 0        |

## Conclusion

L'AUROC=0.987 mesure la **cohérence interne** du clustering EWAT (cible auto-référente), pas la précursion temporelle. Cette critique est **reconnue et adressée** par les Phases B et C ci-après.

Scripts : `experiments/h3_robustness/`.

## Slide 2 — Headline honnête : 0.92 sur cible Chaos Mesh

Évaluation indépendante avec IC bootstrap explicites

### Pivot méthodologique (Phase B + C)

Remplacer la cible (cluster EWAT) par les **15 scénarios Chaos Mesh** (vérité terrain indépendante du pipeline).

### Headline défensif final

| Évaluation                                    | macro-AUROC       | IC 95 % bootstrap     |
|-----------------------------------------------|-------------------|-----------------------|
| H3 circulaire (labels EWAT, à reframer)       | $0.987 \pm 0.011$ | —                     |
| <b>B2 LR-OvR sur Chaos Mesh, v4 _strat</b>    | 0.920             | <b>[0.878, 0.956]</b> |
| <b>B1 best (instance norm + last)</b>         | 0.941             | <b>[0.909, 0.970]</b> |
| LOSO macro-AUROC (15 folds, retrain par fold) | $0.930 \pm 0.007$ | —                     |
| C1 STGCN end-to-end sur Chaos Mesh            | 0.863             | [0.823, 0.905]        |

### Précursion temporelle confirmée (C2-A1)

Sur le modèle STGCN entraîné directement sur Chaos Mesh,  $\Delta(\mathbf{far} - \mathbf{near}) = -0.116$  — la dynamique pré-injection compte pour 12 pp d'AUROC. La fuite que par A1 était un artefact de la circularité, pas la

# Slide 3 — Reframe des contributions

Quatre axes défendables (et un résultat négatif honnête)

- ❶ **Géométrique** (contribution principale et défendable)
  - H1 silhouette =  $0.782 \pm 0.065$  (10 graines, min 0.62)
  - Mismatch corrigé : average+cosine vs ward+euclidean  $\rightarrow +51\%$
- ❷ **Ontologique** (Phase 8, OWL/RDF formelle)
  - 29 classes ancrées littérature (Soldani & Brogi, Fu et al., Gregg, Aniello)
  - 143 individus ABox, 11 object properties, raisonneur HermiT cohérent en 0.61s
  - 3 causales (BH-FDR), 19 co-occurrences, 46 edges propagation
- ❸ **Méthodologique** (stress tests + open-set)
  - 5 stress tests (A1–A5) qui transforment la critique en transparence
  - OpenMax/EVT pour la détection de scénarios inédits (Bendale & Boulton 2016)
- ❹ **Prédictive honnête** (Phase B/C)
  - macro-AUROC = 0.920 sur Chaos Mesh v4\_strat, IC [0.878, 0.956]
  - Précursion temporelle confirmée ( $\Delta(\text{far} - \text{near}) = -0.116$ )

## Résultat négatif assumé

H2a look-through MMD<sup>2</sup> **définitivement falsifié** (v3 :  $p = 0.27$ , v4\_strat :  $p = 0.37$ ). Mécanisme falsifié, pas juste la durée d'épisode.  
Résultat scientifique honnête.

## Bonus — Anticipation des questions

« Votre AUROC=0.987 est suspect »

Oui, et c'est pourquoi nous reportons **0.920 sur Chaos Mesh indépendant (slide 2)**. Le 0.987 est explicitement étiqueté comme cohérence interne du clustering.

« L'encodeur STGCN n'aide pas »

Vrai en agrégé (A5 paired  $\Delta$  IC contient 0). Sa valeur est **géométrique** (H1 sil = 0.78) et **ontologique** (Phase 8). En prédiction agrégée, un LR sur features brutes instance-normalisées suffit (B2 = 0.920).

« Vous évaluez sur les scénarios d'entraînement »

Oui pour H3, et c'est pourquoi nous ajoutons :

- LOSO macro-AUROC =  $0.930 \pm 0.007$  (15 folds, retrain par fold)
- OpenMax/EVT pour les scénarios totalement inédits (Phase C3)
- LOSO top-1 = 0 reconnu comme limitation tautologique d'un classifieur fermé

« Pourquoi ewat\_v4\_strat et pas ewat\_v4 ? »

Le split temporel original ewat\_v4 avait 4 scénarios entièrement absents du training : AUROC = 0.500

# Slide 5 — Validation opérationnelle

Latence end-to-end (C-3) + power statistique (C-5)

## Latence E2E (200 itérations CPU)

| Étape                 | médiane    | p95         | budget      |
|-----------------------|------------|-------------|-------------|
| Drift (0)             | 0.01       | 0.01        | 1000 ms     |
| Encoder+Siamois (1+2) | 0.96       | 1.97        | 2000 ms     |
| Précurseurs (3)       | 1.85       | 3.91        | 1000 ms     |
| <b>TOTAL</b>          | <b>9.3</b> | <b>13.3</b> | <b>5000</b> |

375× sous budget

Verdict : ●

## Power statistique (Hanley-McNeil)

- 5/10 clusters reportables ( $n_{\text{pos}} \geq 5$ )
- Power moyenne sur reportables : 1.0
- C6, C9 ( $n_{\text{pos}} = 1$ ) marqués *non concluant*

**Cible future :**  $n_{\text{pos}} \geq 17$  pour détecter AUROC = 0.7 avec power > 0.8.

## Conclusion

Le pipeline est **opérationnellement viable** (SLA < 5 s largement respecté) et statistiquement défensible sur les 5 clusters reportables. Les 5 autres clusters sont explicitement marqués comme non concluants par manque d'effectif.

# Slide 6 — Limites résiduelles + travaux futurs

8 limites identifiées par audit méthodologique post-Phase C

## Limites résiduelles (docs/limitations.md L10–L17)

| ID  | Limite                                          | Travail futur                         |
|-----|-------------------------------------------------|---------------------------------------|
| L10 | H1 sil = 0.467 sur v4 (surentraînement siamois) | Hard-negative mining + curriculum     |
| L11 | Latence end-to-end                              | ✓ Résolu (C-3, p95 = 13 ms)           |
| L12 | OpenMax Unknown AUROC = 0.55 < 0.7              | Mahalanobis-OOD / Energy / ODIN       |
| L13 | Service graph $N = 6$ vs production 100+        | Benchmark $N \geq 20$                 |
| L14 | Cross-cluster non validé                        | Stratégie B fine-tuning RCAEval (C-2) |
| L15 | Pas de retraining cycle opérationnel            | Drift d'embeddings → trigger retrain  |
| L16 | 17 features hardcodées                          | mRMR / SHAP-based pruning             |
| L17 | Ontologie sans audit SRE                        | 1 séance audit + intégration runbook  |

## Stratégie globale

Chaque limite est documentée transparente *et* accompagnée d'une proposition de fix technique. **Aucune limite cachée**, aucun fix suspect. Le rapport positionne EWAT comme une **contribution mature avec un programme de recherche clair** pour la suite (L13–L17 : 6+ mois de travaux futurs identifiés).